

Analiza performantei unui magazin online

Proiect Pachete Software - Python si SAS

Autori: Sfetcu Vlad Andrei si Simion David
Grupa: 1094

Introducere

Proiectul analizeaza activitatea unui magazin online european care comercializeaza produse pentru cadouri, decoratiuni, bucatarie si articole sezoniere. Obiectivul este evaluarea performantei comerciale si identificarea unor posibilitati de extindere pe baza tranzactiilor, clientilor si pietelor externe.

Setul de date inclus contine 5,598 linii si 14 coloane. Dupa eliminarea liniilor fara client si a retururilor, analiza foloseste 705 clienti, 20 produse si 22 tari.

Venitul total analizat este de aproximativ 468,526.27. Cea mai importanta piata este United Kingdom, iar categoria cu cea mai mare contributie este Kitchen.

Descrierea datelor

Principalele variabile sunt Invoice, StockCode, Description, Category, Quantity, InvoiceDate, Price, Discount, ShippingCost, CustomerID, Country, AcquisitionChannel si RevenueNet. Pentru compatibilitate cu aplicatia Streamlit se calculeaza si $Revenue = Quantity * Price$.

Datasetul este sintetic realist, construit pentru a reproduce situatii economice intalnite in retail: valori lipsa, retururi, comenzi mari, diferente intre piete, discounturi si costuri de transport.

Partea Python - Streamlit

Python 1 - Afisare Streamlit

Definirea problemei: Construirea unei interfete interactive pentru explorarea rapida a activitatii magazinului.

Informatii necesare: Sunt necesare datele tranzactionale si indicatorii de baza: numar tranzactii, clienti unici, produse si tari.

Metode de calcul / algoritmi: Se folosesc `st.metric`, `st.dataframe`, `st.sidebar.radio`, `st.pyplot` si componente de layout pe coloane.

Prezentarea rezultatelor: Aplicatia afiseaza sumarul setului de date, statistici descriptive si primele inregistrari.

Interpretare economica: Managerul poate vedea rapid dimensiunea activitatii si pietele in care magazinul are deja vanzari.

Python 2 - Valori lipsa si extreme

Definirea problemei: Identificarea si tratarea datelor incomplete sau atipice care pot distorsiona analiza.

Informatii necesare: CustomerID are aproximativ 4.48% valori lipsa, iar Description are aproximativ 1.2% valori lipsa.

Metode de calcul / algoritmi: Valorile lipsa din Description se inlocuiesc cu Unknown, iar liniile fara CustomerID se elimina. Outlierii se trateaza prin metoda IQR: $Q1 - 1.5 * IQR$ si $Q3 + 1.5 * IQR$.

Prezentarea rezultatelor: Aplicatia prezinta tabele cu valori lipsa si boxplot-uri inainte si dupa filtrare.

Interpretare economica: Curatarea datelor creste increderea in concluziile privind clientii si produsele profitabile.

Python 3 - Codificarea datelor

Definirea problemei: Transformarea variabilelor categorice in valori numerice pentru algoritmi statistici si ML.

Informatii necesare: Sunt folosite coloane precum Country si AcquisitionChannel.

Metode de calcul / algoritmi: Se aplica LabelEncoder pentru codificare ordinala si pd.get_dummies pentru codificare one-hot.

Prezentarea rezultatelor: Rezultatul este un tabel numeric care poate fi folosit in regresii si clasificari.

Interpretare economica: Codificarea permite includerea pietei geografice in modelele predictive.

Python 4 - Scalarea datelor

Definirea problemei: Aducerea variabilelor numerice la scale comparabile.

Informatii necesare: Se folosesc Quantity, Price si Revenue.

Metode de calcul / algoritmi: StandardScaler aplica $z = (x - \text{media}) / \text{abatere standard}$. MinMaxScaler aplica $(x - \min) / (\max - \min)$.

Prezentarea rezultatelor: Aplicatia compara distributiile originale cu cele standardizate si normalizate.

Interpretare economica: Scalarea este necesara pentru K-Means si ajuta modelele sa nu fie dominate de variabile cu valori mari.

Python 5 - Pandas groupby si agregari

Definirea problemei: Calcularea indicatorilor de performanta pe tari, luni, produse si categorii.

Informatii necesare: Sunt necesare variabilele Country, InvoiceDate, Description, Quantity, Price si Revenue.

Metode de calcul / algoritmi: Se utilizeaza groupby, agg, sum, mean, count si nunique.

Prezentarea rezultatelor: Cea mai mare piata este United Kingdom cu venituri de aproximativ 227,435.36.

Interpretare economica: Agregarea pe tari indica unde firma este puternica si unde poate investi pentru extindere.

Python 6 - Reprezentari grafice

Definirea problemei: Vizualizarea evolutiei si structurii vanzarilor.

Informatii necesare: Sunt necesare seriile lunare, topurile pe tari si distributiile numerice.

Metode de calcul / algoritmi: Se folosesc matplotlib, seaborn, barplot, line chart, histogram si heatmap.

Prezentarea rezultatelor: Graficele evidentiaza topul tarilor, produsele principale si sezonabilitatea.

Interpretare economica: Vizualizarile faciliteaza deciziile de marketing si stocuri.

Python 7 - Geopandas

Definirea problemei: Analiza spatiala a vanzarilor pe tari.

Informatii necesare: Sunt necesare veniturile agregate pe Country si geometria tarilor din Natural Earth.

Metode de calcul / algoritmi: Se face merge între GeoDataFrame și tabelul de venituri, apoi se construiește o hartă coropletică.

Prezentarea rezultatelor: Aplicația afișează harta Europei și harta globală a vânzărilor.

Interpretare economică: Piete apropiate geografic cu vânzări reduse pot fi propuse pentru extindere controlată.

Python 8 - Clusterizare K-Means

Definirea problemei: Segmentarea clienților după comportamentul de cumpărare.

Informații necesare: Se calculează variabile RFM: Recency, Frequency și Monetary.

Metode de calcul / algoritmi: Datele RFM sunt standardizate, apoi se aplică KMeans. Calitatea segmentării se evaluează cu silhouete score.

Prezentarea rezultatelor: Rezultatul este un profil pe clustere: clienți valoroși, clienți ocazionali, clienți la risc și clienți noi.

Interpretare economică: Segmentarea ajută la campanii diferențiate și la creșterea retenției.

Python 9 - Regresie logistică

Definirea problemei: Estimarea probabilității ca un client să revină în a doua parte a perioadei analizate.

Informații necesare: Se folosesc indicatorii clienților din prima parte a perioadei și eticheta Returned.

Metode de calcul / algoritmi: Datele sunt împărțite train/test, scalate cu MinMaxScaler și modelate cu LogisticRegression.

Prezentarea rezultatelor: Aplicația afișează matricea de confuzie, raportul de clasificare și curba ROC-AUC.

Interpretare economică: Modelul poate orienta campaniile de retenție către clienții cu risc de pierdere.

Python 10 - Regresie multiplă Statsmodels

Definirea problemei: Determinarea factorilor care influențează valoarea unei comenzi.

Informații necesare: Variabila dependentă este $\log(\text{Revenue})$, iar predictorii includ cantitatea, prețul, produse unice, ziua, ora, luna și țara.

Metode de calcul / algoritmi: Se folosește OLS din statsmodels, cu interpretarea coeficienților, p-value, R-squared și teste de diagnostic.

Prezentarea rezultatelor: Aplicația afișează coeficienții și comparația valori prezise vs reale.

Interpretare economică: Rezultatele susțin strategii de cross-selling și optimizare a prețurilor.

Partea SAS

SAS 1 - Import fișier extern

Definirea problemei: aplicarea facilității SAS pentru analiza acelui set de date.

Informații necesare: fișierul data/online_retail_project.csv și variabilele tranzacționale.

Metode de calcul / algoritmi: PROC IMPORT creează work.retail_raw din CSV-ul proiectului.

Prezentarea rezultatelor: rezultatele sunt afișate în Output Viewer și salvate parțial în bibliotecă out.

Interpretare economica: rezultatele SAS confirma pietele, produsele si segmentele relevante pentru extinderea magazinului.

SAS 2 - Formate definite de utilizator

Definirea problemei: aplicarea facilitatii SAS pentru analiza aceluiasi set de date.

Informatii necesare: fisierul data/online_retail_project.csv si variabilele tranzactionale.

Metode de calcul / algoritmi: PROC FORMAT defineste formate pentru venit, cantitate si regiune.

Prezentarea rezultatelor: rezultatele sunt afisate in Output Viewer si salvate partial in biblioteca out.

Interpretare economica: rezultatele SAS confirma pietele, produsele si segmentele relevante pentru extinderea magazinului.

SAS 3 - Procesare conditionala si iterativa

Definirea problemei: aplicarea facilitatii SAS pentru analiza aceluiasi set de date.

Informatii necesare: fisierul data/online_retail_project.csv si variabilele tranzactionale.

Metode de calcul / algoritmi: DATA step calculeaza venituri, tip tranzactie, regiune si scor comercial.

Prezentarea rezultatelor: rezultatele sunt afisate in Output Viewer si salvate partial in biblioteca out.

Interpretare economica: rezultatele SAS confirma pietele, produsele si segmentele relevante pentru extinderea magazinului.

SAS 4 - Subseturi de date

Definirea problemei: aplicarea facilitatii SAS pentru analiza aceluiasi set de date.

Informatii necesare: fisierul data/online_retail_project.csv si variabilele tranzactionale.

Metode de calcul / algoritmi: Se creeaza seturile sales, returns si customers_known.

Prezentarea rezultatelor: rezultatele sunt afisate in Output Viewer si salvate partial in biblioteca out.

Interpretare economica: rezultatele SAS confirma pietele, produsele si segmentele relevante pentru extinderea magazinului.

SAS 5 - Functii SAS

Definirea problemei: aplicarea facilitatii SAS pentru analiza aceluiasi set de date.

Informatii necesare: fisierul data/online_retail_project.csv si variabilele tranzactionale.

Metode de calcul / algoritmi: Se folosesc input, anydtdtm, datepart, month, year, weekday, missing si put.

Prezentarea rezultatelor: rezultatele sunt afisate in Output Viewer si salvate partial in biblioteca out.

Interpretare economica: rezultatele SAS confirma pietele, produsele si segmentele relevante pentru extinderea magazinului.

SAS 6 - SQL si combinare seturi

Definirea problemei: aplicarea facilitatii SAS pentru analiza aceluiasi set de date.

Informatii necesare: fisierul data/online_retail_project.csv si variabilele tranzactionale.

Metode de calcul / algoritmi: PROC SQL construiește sumarul pe țări și îmbogățește tranzacțiile cu indicatori de țară.

Prezentarea rezultatelor: rezultatele sunt afișate în Output Viewer și salvate parțial în bibliotecă out.

Interpretare economică: rezultatele SAS confirmă piete, produsele și segmentele relevante pentru extinderea magazinului.

SAS 7 - Masive

Definirea problemei: aplicarea facilității SAS pentru analiza acelui set de date.

Informații necesare: fișierul data/online_retail_project.csv și variabilele tranzacționale.

Metode de calcul / algoritmi: Array-ul components parcurge Quantity, Price și Revenue pentru PotentialScore.

Prezentarea rezultatelor: rezultatele sunt afișate în Output Viewer și salvate parțial în bibliotecă out.

Interpretare economică: rezultatele SAS confirmă piete, produsele și segmentele relevante pentru extinderea magazinului.

SAS 8 - Raportare

Definirea problemei: aplicarea facilității SAS pentru analiza acelui set de date.

Informații necesare: fișierul data/online_retail_project.csv și variabilele tranzacționale.

Metode de calcul / algoritmi: PROC PRINT și PROC REPORT prezintă topul țărilor și raportul pe regiuni.

Prezentarea rezultatelor: rezultatele sunt afișate în Output Viewer și salvate parțial în bibliotecă out.

Interpretare economică: rezultatele SAS confirmă piete, produsele și segmentele relevante pentru extinderea magazinului.

SAS 9 - Statistica și grafice

Definirea problemei: aplicarea facilității SAS pentru analiza acelui set de date.

Informații necesare: fișierul data/online_retail_project.csv și variabilele tranzacționale.

Metode de calcul / algoritmi: PROC MEANS, PROC CORR, PROC REG și PROC SGPLOT produc statistici, regresii și grafice.

Prezentarea rezultatelor: rezultatele sunt afișate în Output Viewer și salvate parțial în bibliotecă out.

Interpretare economică: rezultatele SAS confirmă piete, produsele și segmentele relevante pentru extinderea magazinului.

SAS 10 - SAS ML

Definirea problemei: aplicarea facilității SAS pentru analiza acelui set de date.

Informații necesare: fișierul data/online_retail_project.csv și variabilele tranzacționale.

Metode de calcul / algoritmi: PROC FASTCLUS realizează clusterizare RFM pentru segmentarea clienților.

Prezentarea rezultatelor: rezultatele sunt afișate în Output Viewer și salvate parțial în bibliotecă out.

Interpretare economică: rezultatele SAS confirmă piete, produsele și segmentele relevante pentru extinderea magazinului.

Concluzii

Magazinul are cea mai buna performanta in United Kingdom, iar extinderea ar trebui orientata catre tari europene cu proximitate geografica si venituri in crestere.

Clientii pot fi impartiti in segmente prin RFM, ceea ce permite campanii diferite: retentie pentru clientii la risc, oferte premium pentru clientii valorosi si activare pentru clientii ocazionali.

Modelele de regresie si clasificare completeaza analiza descriptiva si transforma proiectul intr-un instrument de decizie pentru management.

Fisiere livrate

Fisier	Rol
app.py	Aplicatia Streamlit
data/online_retail_project.csv	Setul de date
sas/analiza_magazin_online.sas	Programul SAS
requirements.txt	Dependinte Python